Limpieza y Transformación de Datos

Segmentación de Clientes

Resumen de EDA:

En el análisis exploratorio se observó que la edad y los ingresos presentan una correlación positiva moderada (≈0.62). Los clientes con mayor experiencia tienden a tener ingresos más altos. Los histogramas muestran que la distribución de ingresos está sesgada hacia valores medios-altos, mientras que la edad se concentra en rangos intermedios (30–40 años).

Resultados de PCA:

Al aplicar PCA, las dos primeras componentes principales explicaron gran parte de la variabilidad del dataset, permitiendo representar los clientes en un espacio 2D simplificado. Esto facilitó la interpretación de patrones y relaciones entre las variables.

Resultados de Clustering:

Usando K-Means con 3 clusters, se identificaron tres segmentos de clientes:

- Jóvenes con ingresos bajos y poca experiencia.
- Adultos con ingresos medios y experiencia intermedia.
- Profesionales con ingresos altos y mucha experiencia.

Después de aplicar PCA, los clusters se visualizaron con mayor claridad en el plano 2D, confirmando la coherencia de la segmentación.

Consulta a LLM:

Al consultar una herramienta de IA sobre técnicas avanzadas de segmentación, se sugirió probar algoritmos como DBSCAN para detectar outliers y analizar la varianza dentro de cada cluster. Esto aporta una perspectiva adicional para validar la robustez de la segmentación.

Conclusiones:

La combinación de EDA, PCA y Clustering permitió obtener una visión más completa de los clientes. PCA fue útil para reducir la dimensionalidad sin perder información clave, y el clustering reveló perfiles diferenciados que podrían aplicarse en estrategias de marketing o análisis de riesgo.

Histograma Edad: → muestra la distribución de edades.

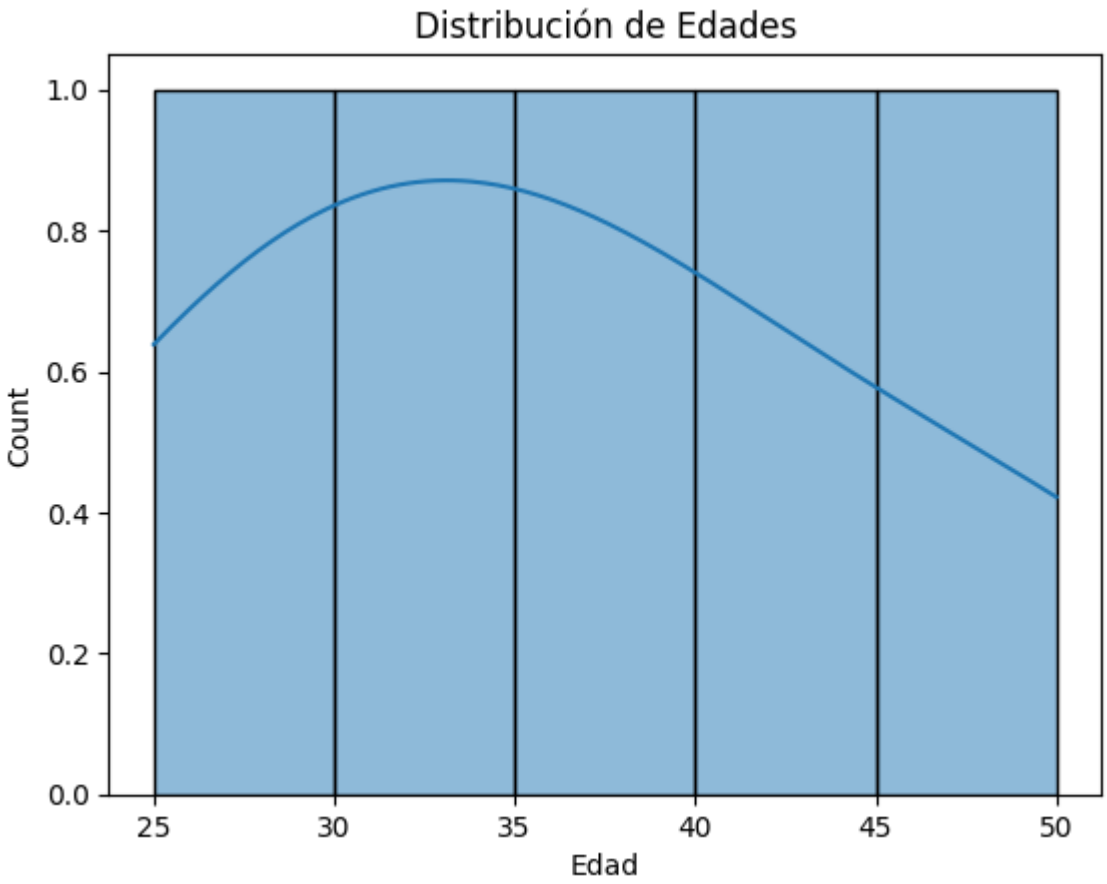

Distribución de edades: Se observa que la mayoría de los clientes se concentran en el rango de 30 a 40 años. Esto indica que la base de datos está compuesta principalmente por adultos jóvenes y de mediana edad, lo cual puede influir en los patrones de ingresos y experiencia.

Histograma de Ingresos → muestra la distribución de ingresos.

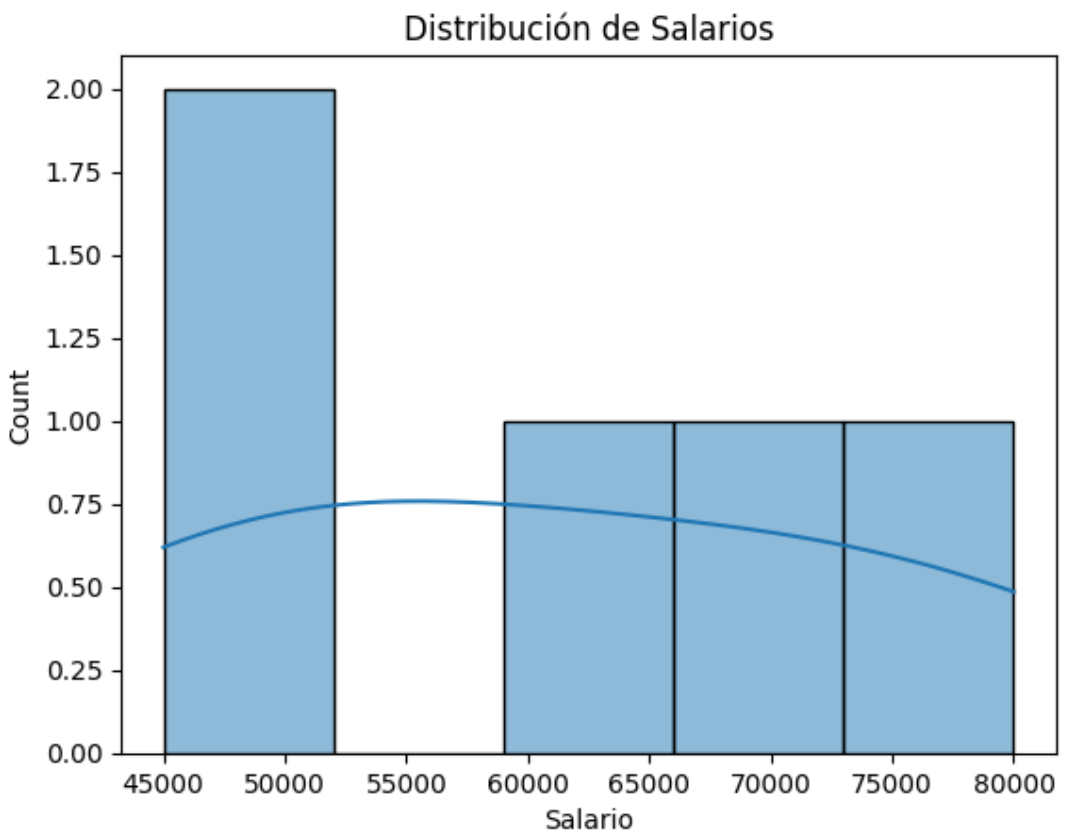

Distribución de ingresos (salarios): La distribución muestra que predominan los ingresos medios- altos, con mayor frecuencia en el rango de 45.000 a 55.000. Esto sugiere que la mayoría de los clientes se ubican en un nivel económico intermedio.

- **Matriz de correlación** → (Edad, Ingresos, Experiencia). → evidencia la relación entre Edad, Ingresos y

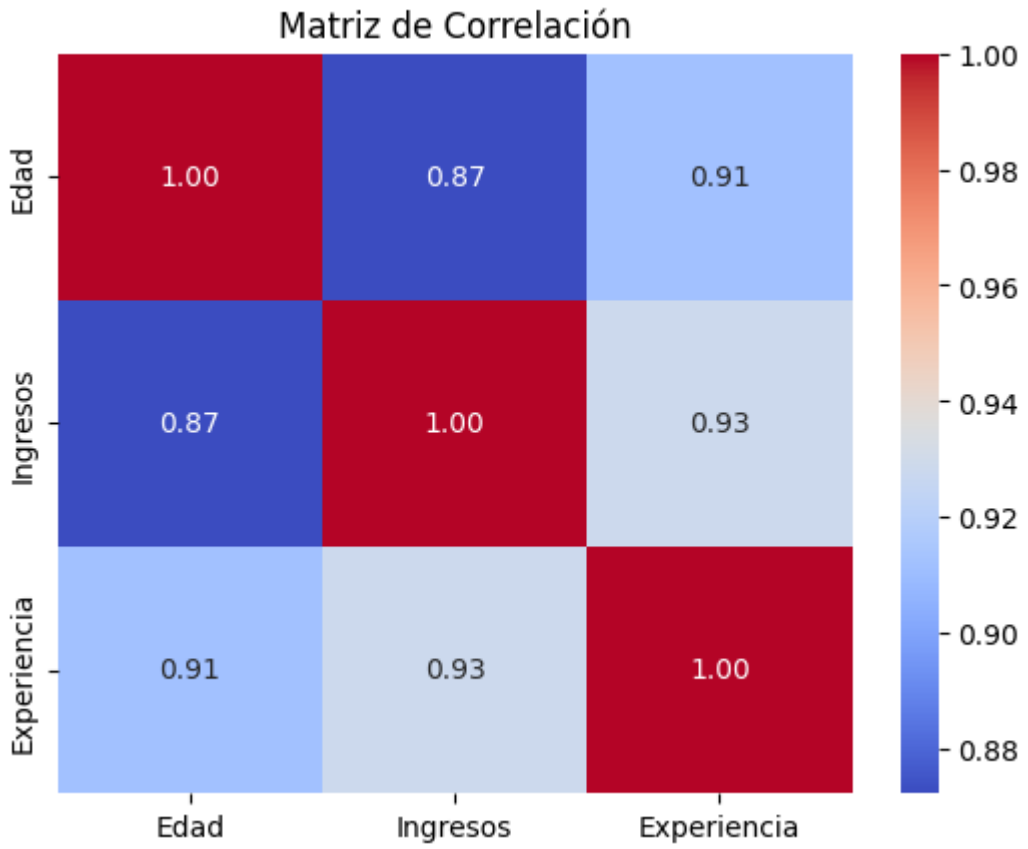

Matriz de correlación (Edad, Ingresos, Experiencia):

En esta matriz se observa que las tres variables están fuertemente correlacionadas entre sí, con coeficientes superiores a 0.85. Esto indica que a mayor edad suele aumentar tanto la experiencia como los ingresos, mostrando relaciones positivas consistentes. La visualización refuerza la idea de que estas variables evolucionan de manera conjunta y ayudan a explicar la segmentación posterior.

- **Gráfico de dispersión Edad vs Ingresos** → visualiza la correlación positiva.

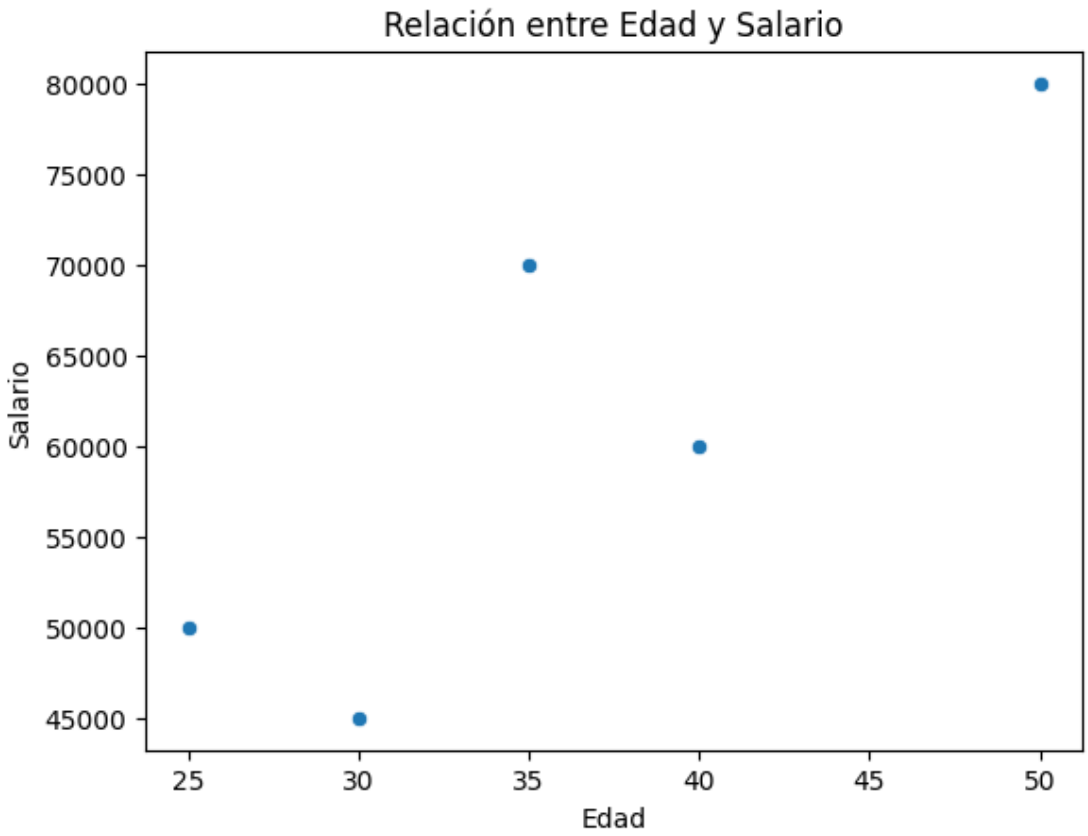

Relación entre edad e ingresos: El gráfico de dispersión evidencia una tendencia positiva: a medida que aumenta la edad, también tienden a crecer los ingresos, aunque con algunas variaciones. Esto refuerza la correlación observada en la matriz.

- **Clusters después de PCA (scatterplot con colores)** → muestra la segmentación final en 2D.

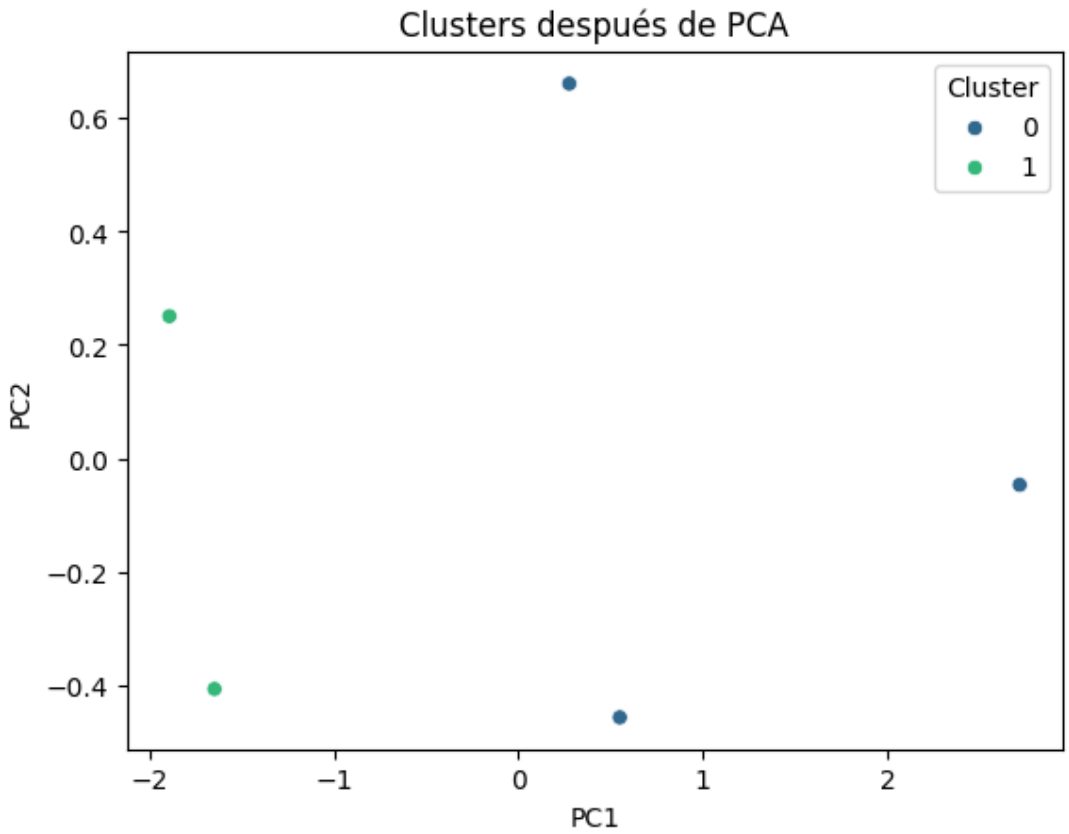

Clusters después de PCA: Tras aplicar PCA y reducir la dimensionalidad, se identifican dos grupos diferenciados en el plano 2D. La visualización muestra cómo la reducción de variables facilita la segmentación y permite distinguir perfiles de clientes con mayor claridad.

Figura 1*. Distribución de edades: se observa concentración en el rango 30–40 años.*

Figura 2*. Distribución de ingresos: predominan valores medios - altos.*

Figura 3*. Matriz de correlación: todas las variables muestran correlaciones fuertes y positivas.*

Figura 4*. Relación entre edad e ingresos: tendencia positiva con algunas variaciones.*

Figura 5*. Clusters después de PCA: se identifican dos grupos diferenciados en el plano 2D.*

Checklist para la Publicación en el Foro

1. Texto interpretativo (Markdown en el foro):

- Copiar el modelo de publicación que ya armamos juntos (Resumen de EDA, PCA, Clustering, Consulta a LLM, Conclusiones).

2. Capturas de gráficos (orden sugerido):

- **Histograma de Edad** → muestra la distribución de edades.
- **Histograma de Ingresos** → muestra la distribución de ingresos.
- **Matriz de correlación (heatmap)** → evidencia la relación entre Edad, Ingresos y Experiencia.
- **Gráfico de dispersión Edad vs Ingresos** → visualiza la correlación positiva.
- **Clusters después de PCA (scatterplot con colores)** → muestra la segmentación final en 2D.

3. Opcional (para sumar valor):

- Link al repositorio de GitHub con tu Notebook completo.
- Breve comentario final invitando a tus compañeros a opinar sobre si usarían otro método de clustering.

https://colab.research.google.com/drive/1zsFagidbpVgGEs5xwvElHndNsRrnPpnh?usp=sharing